


需求一：

有缓存，当我在设置中新增模型后，这里没有读取到最新新增的模型




需求二：

如果有使用到 ocr，需要分开计时，ocr 的时间，llm 的时间




需求三：

评分详情需要支持重试，取最新定义的评价标准，重新跑一遍，新详情可以直接覆盖老的评分详情的内容




bug:

用例有 10 个，跑了 9 个，但执行历史已经显示状态已完成，列表中的评测集还显示为运行中




需求:

将这个中止按钮干掉




Bug:

画面中会出现这些所谓测试用例的内容，然后刷新一下页面后又没了，有时候会到 20 个，感觉是把别的评测集的记录也读取过来了




需求:

这个执行历史的进度条是假的，没有按照实际的进度走




技术要求：

评测集的执行是否需要设计一套消息队列？以供读取实际的处理进度，因为处理的时长确实很长，或者是否有其它好的技术方案？



需求：

需要支持勾选部分用例执行运行评测



需求：

单个测试用例的结果区域需要增加重试功能，重试后的结果可以直接覆盖原结果上，不用自动执行 ai 评测，让用户自己决定是否需要 ai 评测，因为是有 ai 评测重试的功能的

